

Taller de Complejidad Algorítmica (Big O)

Nombre: Juan Andres Salazar Urdinola
Código: 2262431-2724

Objetivo: Demostrar el crecimiento asintótico de funciones mediante límites y analizar/escribir algoritmos eficientes en Python.

Módulo 1: El Rigor Matemático (Criterio del Límite)

Para cada ejercicio, utiliza la fórmula:

$$\lim_{n \rightarrow \infty} \frac{f(n)}{g(n)}$$

Si $L=0$, entonces $f(n) = O(g(n))$. Si $L=c$, entonces $f(n) = \Theta(g(n))$.

Ejercicio 1.1 (Nivel Básico):

Demuestre que $F(n) = 7n^2 + 5n + 2$ es de orden $O(n^2)$

$$\lim_{n \rightarrow \infty} \frac{F(n)}{g(n)} = \lim_{n \rightarrow \infty} \frac{(7n^2 + 5n + 2)}{n^2} = 7 + \frac{5}{n} + \frac{2}{n^2}$$

$$\lim_{n \rightarrow \infty} \frac{5}{n} = 0 \quad \lim_{n \rightarrow \infty} \frac{2}{n^2} = 0 \quad \text{Límite} = 7$$

Como el límite es un número Finito

$\text{Límite} = 7$ (constante $\neq 0$) $= F(n) = O(n^2)$,
por lo tanto también $O(n^2)$

Ejercicio 1.2 (Nivel Intermedio):

Demuestra que la función lineal $g(n) = n$ es una cota superior para la función logarítmica

Demuestre que la función lineal $g(n) = n$ es una cota superior para la función logarítmica

$f(n) = \ln(n)$ es decir, demuestra que $\ln(n) = O(n)$

$$\ln(n) = O(n) \quad \lim_{n \rightarrow \infty} \frac{\ln(n)}{n}$$

$$\frac{d}{dn} (\ln n) = \frac{1}{n} = \frac{d}{dn} (n) = 1$$

$$\lim_{n \rightarrow \infty} \frac{1}{n} = 0 \quad \text{Como el límite es } 0$$

El logaritmo crece más lento que la función lineal

Ejercicio 1.3 (Nivel Avanzado):

Determina la relación asintótica entre $f(n) = n!$ (factorial) y $g(n) = 2^n$ ¿Cuál crece más rápido?

$$f(n) = n! \quad g(n) = 2^n \quad \text{para } n > 2$$

$$\lim_{n \rightarrow \infty} \frac{n!}{2^n} = \frac{1 \cdot 2 \cdot 3 \cdot 4 \cdot 5}{2^2 \cdot 2^2} = \frac{3}{2} > 1$$
$$\frac{4}{2} > 1$$

$$\frac{5}{2} > 1$$

Se puede observar que mediante números mayores que 1 por ende crece sin límite

$$\lim_{n \rightarrow \infty} \frac{n!}{2^n} = \infty \quad \text{el factorial crece mas rápido } 2^n = O(n!) \\ n! \neq O(2^n)$$

Módulo 2: Análisis de Algoritmos (Lectura de Código)

Analiza los siguientes fragmentos de código en Python. Para cada uno, identifica: Mejor Caso, Peor Caso y la Notación Big O.

Ejercicio 2.1: El buscador de pares

```
def buscar_par_especifico(lista, objetivo):
    # Analiza este código
    pasos = 0
    for i in range(len(lista)):
        pasos += 1
        if lista[i] % 2 == 0 and lista[i] == objetivo:
            return True, pasos
    return False, pasos
```

Mejor Caso O(1): El primer elemento de la lista es par e igual al objetivo. El bucle se ejecuta una sola vez y retorna inmediatamente.

Peor Caso O(n): El objetivo no existe en la lista o está en la última posición. Se recorren todos los n elementos.

Big O General: O(n) — El algoritmo realiza una sola pasada lineal sobre la lista. El número de operaciones es proporcional al tamaño de la entrada.

Ejercicio 2.2: El salto de índices

```
def algoritmo_misterioso(n):
    # Analiza el crecimiento de 'i'
    i = 1
    operaciones = 0
    while i < n:
        operaciones += 1
        i = i * 2
    return operaciones
```

La clave está en cómo crece i . La secuencia de valores es: 1, 2, 4, 8, 16, ..., 2^k

El bucle termina cuando $2^k \geq n$, es decir, cuando $k \geq \log_2(n)$.

Mejor Caso O(1): Si $n \leq 1$, el while nunca se ejecuta (0 iteraciones).

Peor Caso O($\log n$): El número de iteraciones es exactamente $\lfloor \log_2(n) \rfloor$.

Big O General: O($\log n$) — Cada iteración duplica el valor de i , reduciendo a la mitad el espacio restante. Este patrón de crecimiento geométrico produce complejidad logarítmica

Módulo 3: Implementación (Programación)

En esta parte debes escribir código que cumpla con las restricciones de eficiencia solicitadas.

Ejercicio 3.1: Intersección de Listas

Escribe una función en Python llamada interseccion(lista1, lista2) que devuelva los elementos comunes.

```
def ejercicio_3_1():
    print("--- Ejercicio 3.1: Intersección de Listas ---")

    lista1 = [1, 3, 5, 7, 9, 11, 13, 15, 17, 19]
    lista2 = [3, 6, 9, 12, 15, 18]

    res_ingenua = interseccion_ingenua(lista1, lista2)
    res_set     = interseccion_con_set(lista1, lista2)

    print(f"  Lista 1: {lista1}")
    print(f"  Lista 2: {lista2}")
    print(f"  Resultado (ingenua O(n²)): {sorted(res_ingenua)}")
    print(f"  Resultado (set      O(n)):   {sorted(res_set)}")
    print(f"  ¿Coinciden?: {sorted(res_ingenua) == sorted(res_set)}\n")
```

Reto A: Impleméntalo de forma "ingenua" usando bucles anidados ($O(n^2)$).

```
# --- RETO A: Versión Ingenua  $O(n^2)$  ---

def interseccion_ingenua(list1, lista2):
    resultado = []
    for elemento in list1:           #  $O(n)$ 
        for otro in lista2:          #  $O(m)$  por cada elemento
            if elemento == otro:
                if elemento not in resultado:
                    resultado.append(elemento)
    return resultado
```

Reto B: Investiga cómo hacerlo usando un set (conjunto) en Python para lograr una complejidad de $O(n)$.

```
# --- RETO B: Versión con Set  $O(n)$  ---

def interseccion_con_set(list1, lista2):

    set_lista2 = set(lista2)           #  $O(m)$ : construir el set
    resultado = []
    for elemento in list1:           #  $O(n)$ : un solo recorrido
        if elemento in set_lista2:   #  $O(1)$ : búsqueda por hash
            resultado.append(elemento)
    return list(set(resultado))      # Eliminar posibles duplicados
```

Documentación: Explica por qué la versión con set es más rápida basándote en lo visto en el Módulo 1.

R/Un set en Python implementa internamente una tabla hash. Esto garantiza que la operación "in" tenga complejidad $O(1)$ promedio en lugar de $O(n)$ como en una lista.

Aplicando el criterio del límite del Módulo 1:

$$\lim_{n \rightarrow \infty} n / n^2 = \lim_{n \rightarrow \infty} 1/n = 0$$

Como $L = 0$, se confirma que $O(n) \subset O(n^2)$ (la solución con set es asintóticamente inferior y mucho más eficiente para entradas grandes).

Ejercicio 3.2: El desafío del crecimiento exponencial

Escribe una función recursiva para calcular el número de Fibonacci: $F(n) = F(n-1) + F(n-2)$.

```
def fibonacci(n):  
    # Casos base  
    if n < 0:  
        raise ValueError("El número debe ser mayor o igual a 0")  
    if n == 0:  
        return 0  
    if n == 1:  
        return 1  
  
    # Caso recursivo:  $F(n) = F(n-1) + F(n-2)$   
    return fibonacci(n - 1) + fibonacci(n - 2)  
  
  
  
  
for i in range(10):  
    print(f"F({i}) = {fibonacci(i)}")
```

Salida

- PS C:\Users\juan_\OneDrive\Desktop\Taller_Complejidad_Algoritmica> & C:/Users/juan_/AppData/Local/Python/bin/python.exe c:/Users/juan_/OneDrive/Desktop/Taller_Complejidad_Algoritmica/1.py
F(0) = 0
F(1) = 1
F(2) = 1
F(3) = 2
F(4) = 3
F(5) = 5
F(6) = 8
F(7) = 13
F(8) = 21
F(9) = 34

Analiza por qué esta implementación simple es $O(2^n)$.

R/Cada llamada a $\text{fibonacci}(n)$ genera exactamente 2 llamadas recursivas. El árbol de recursión tiene profundidad n y se expande geométricamente:

$$T(n) = T(n-1) + T(n-2) + O(1) \rightarrow T(n) \approx 2^n$$

Además, el algoritmo recalcula los mismos subproblemas múltiples veces. Por ejemplo, $F(3)$ se calcula en varias ramas del árbol.

Pregunta técnica: Si $n=50$, ¿por qué tu computadora probablemente se bloquee al intentar calcularlo?

R/Con $n = 50$, el número de llamadas recursivas es aproximadamente:

$$2^{50} \approx 1,125,899,906,842,624 \ (\approx 1 \text{ cuatrillón de operaciones})$$

Incluso a 10^9 operaciones/segundo (procesador moderno), esto tomaría ~ 13 días. La memoria de la pila de llamadas (stack) también se agota por la profundidad de recursión.